

Caracterización de posiciones en el fútbol femenino usando análisis estadístico y modelos predictivos

ADRIANA SEGOVIA RIVERA

Mayo 2026

1. Resumen

El análisis de las posiciones en el fútbol femenino es de gran relevancia para comprender el rendimiento de las jugadoras dentro del campo. En este artículo se estudia una base de datos de la National Women's Soccer League (NWSL), mediante la aplicación de diversas técnicas de análisis estadístico.

Se emplearon métodos como diferencia de medias, diagramas de caja (boxplots) y modelos de clasificación basados en inteligencia artificial.

Los resultados muestran diferencias significativas en las características de las jugadoras según su posición, lo que permite identificar patrones de desempeño específicos y contribuir a una mejor evaluación del rendimiento deportivo.

Abstract The analysis of positions in women's soccer is highly relevant for understanding players' performance on the field. This study examines a dataset from the National Women's Soccer League (NWSL) through the application of various statistical techniques.

Methods such as mean difference analysis, boxplots, correlation analysis, machine learning classifiers, linear regression, and scatter plots were used to identify performance patterns according to player positions.

The results show significant differences in performance characteristics across positions, allowing the identification of specific player profiles and contributing to a more accurate evaluation of performance in women's soccer.

Palabras clave Fútbol femenino, Análisis estadístico, NWSL, Regresión lineal, Correlación, Inteligencia artificial.

2. Introducción

El fútbol ha sido históricamente uno de los deportes más populares y a pesar de que se ha dicho que es un deporte para hombres en los últimos años ha tomado relevancia en el ámbito femenino. En muchos países sigue siendo, un deporte que se le ha privado a muchas generaciones de mujeres, no solo de jugarlo sino también de poder contar con un referente en este sector, y con el que se sintieran identificadas o al que pudiesen admirar o inspirarse. El fútbol femenino tiene un papel importante en la sociedad, aunque queda un camino muy largo para lograr obtener la misma relevancia en equipos femeniles y varoniles. [1]

El fútbol femenino ha generado un gran interés entre los investigadores, abordando proyectos relacionados con el rendimiento de las deportistas, aumentando los estudios sobre la competición. [2]

El uso de datos a significado bastante en este ultimo año, estudiar la actividad que el futbolista realiza durante el partido es imprescindible para planificar su entrenamiento, ajustando así de la manera más precisa posible los medios y procedimientos que permitan preparar al jugador y obtener de él un mayor rendimiento en el juego. [3].

Diversos estudios se han centrado en el análisis de comportamientos tácticos y técnicos mediante el uso de herramientas tecnológicas, las cuales han sido clave para comprender la dinámica de la competición y aplicar este conocimiento en distintos niveles de rendimiento. En cuanto a la técnica y su relevancia, autores, como

Konefal et al. (2020), afirman que el éxito de un equipo al final de temporada está asociado al rendimiento técnico. [2]

Por lo tanto, el objetivo de este estudio es analizar una base de datos proveniente de la plataforma Kaggle, los datos fueron previamente procesados, incluyendo la limpieza de información y la incorporación de variables adicionales, como la posición de cada jugadora. Este análisis permite identificar habilidades, fortalezas y debilidades, así como estudiar la relación entre la posición en el campo y el desempeño estadístico.

3. Metodología

3.1. Descripción de los datos

La base de datos utilizada se obtuvo del sitio web (Kaggle), llamada 2024 NWSL Womens Soccer League Player Stats FULL, perteneciente a la Liga Nacional de Fútbol Femenino, es la principal liga de fútbol profesional femenino, con jugadores de la selección nacional de todo el mundo.

Los clubes pertenecientes son Angel City FC, Bay FC, Boston Legacy FC, Chicago Stars FC, Denver Summit FC, Gotham FC, Houston Dash, Kansas City Current, North Carolina Courage, Orlando Pride, Portland Thorns FC, Racing Louisville FC, San Diego Wave FC, Seattle Reign FC, Utah Royals FC y Washington Spirit.

En esta base de datos se pueden encontrar estadísticas completas de jugadoras de la NWSL 2024 se actualiza mensualmente a medida que avanza la temporada, para la realización de este artículo el archivo actual abarca la temporada 2024 hasta el 25 de mayo de 2024. Los datos de esta base se han extraído principalmente de NWSL.com. Se han limpiado y se ha añadido información adicional, como la posición.

3.2. Descripción de variables de la base de datos

Variable	Descripción
team	Equipo
player_name	Nombre del jugador
conc_player_name	Nombre
position	Posición
games_played	Juegos jugados
games_started	Juegos iniciados
minutes_played	Minutos jugados
goals	Goles
accurate_pass_percentage	Precisión de pase
assists	Asistencias
total_scoring_attempts	Intentos totales de gol
on_target_scoring_attempts	Intentos o tiros a puerta
total_attacking_assists	Asistencias de ataque totales
tackles	Entradas defensivas
fouls_committed	Faltas cometidas
fouls_suffered	Faltas sufridas
total_offside	Fuera de juego
yellow_cards	Tarjetas amarillas
red_cards	Tarjetas rojas
accurate_passes	Pases precisos
total_passes	Total de pases

crosses	Centros
assists_avg_over_90_mins	Promedio de asistencias cada 90 minutos
long_balls	Balones largos
successful_short_passes	Pases cortos exitosos
turnovers	Pérdida de balón
goals_avg_over_90_mins	Promedio de goles cada 90 minutos
penalty_kick_goals	Penales convertidos en gol
penalty_kick_taken	Penales ejecutados
penalty_kick_percentage	Efectividad en penales
accurate_shooting_percentage	Precisión de tiro
successful_dribble	Regate exitoso
dribble_percentage	Tasa de éxito en regate
goals_and_assists	Goles y asistencias
tackles_percentage	Porcentaje de entradas
interceptions	Intercepciones
headed_duel	Duelos aéreos de cabeza
gk_saves	Atajadas de la portera
gk_long_ball_percentage	Efectividad en pases largos de la portera
gk_total_clearance	Despejes totales de la portera

3.3. Procesamiento de datos

Durante el preprocesamiento de datos se identificó que la variable **'tackles'** se encontraba duplicada, por lo que se conservó únicamente una de ellas.

Dado que la variable objetivo del estudio fue position (posición) las cuales son: **MIDFIELDER = Centrocampista**, **DEFENDER = Defensa**, **FORWARD = Delantera**, **GOALKEEPER = Portera** se eliminaron aquellas columnas que no aportaban información relevante para el análisis o la clasificación de las jugadoras.

Entre las variables eliminadas se encuentran:

- player_name
- team
- conc_player_name
- penalty_kick_percentage
- penalty_kick_taken
- penalty_kick_goals
- games_started

Asimismo, con el objetivo de considerar únicamente jugadoras con participación activa durante el torneo, se aplicó la condición **minutes_played > 0**. Como resultado del proceso de limpieza y filtrado de datos, el conjunto final quedó conformado por 308 jugadoras de un total inicial de 343.

3.4. Descripción de posiciones

El Fútbol es un juego de conjunto, donde la estrategia que se elija resulta fundamental para el desarrollo del partido. Hay diferentes tácticas o sistemas de juego que cada equipo adopta para jugar, dependiendo de las características de sus elementos, de la filosofía de juego que tenga el entrenador y del rival al que se enfrentaran.

La función específica que cada jugador debe desarrollar durante el juego depende de sus características personales:

- **GOALKEEPER = Portera**

Aunque su función principal es impedir que el equipo contrario anote gol en la portería que defiende, actualmente por su posición privilegiada para leer el juego, la portera debe dirigir con su voz los movimientos de su defensa, es el jefe de la defensa, debe ser decidida y muy atenta al juego, debe tener seguridad en los despejes y en las salidas, estar dispuesta a realizar coberturas y ser astuta en los contraataques.

- **DEFENDER = Defensa**

Las defensas son los encargados de evitar que el equipo contrario genere situaciones de gol, realizando marcajes de zona o personales, también inician las ofensivas de su equipo, son especialistas en despejes con pies y cabeza, con técnica de control de balón y pase, poseen un gran sentido de anticipación, hacen coberturas y saben incorporarse al ataque.

- **MIDFIELDER = Centrocampista**

Son quienes sirven de apoyo y enlace entre defensas y delanteras, son quienes dirigen las acciones estratégicas del encuentro, deben ser resistentes, rápidas, potentes y veloces, además poseen calidad técnica en todos los aspectos, fundamentalmente en el control y el pase, saben desmarcarse y tienen sentido de anticipación.

- **FORWARD = Delantera**

La misión de las delanteras radica en convertir en gol las acciones de sus compañeras, deben poseer un gran nivel técnico, con muchos recursos para burlar a las defensas, saben rematar con pies y cabeza, tienen buena profundidad, progresión en el juego y buscan con obsesión el gol.

3.5. Métodos estadísticos

3.5.1. Diferencia de medias / prueba t

La prueba t de Student y la diferencia de medias son métodos estadísticos utilizados para comparar si existen diferencias significativas entre los promedios de dos grupos. En este estudio, estas pruebas permiten analizar si determinadas variables estadísticas presentan diferencias entre las posiciones de las jugadoras.

La diferencia de medias consiste en comparar el valor promedio de una variable entre dos grupos. Matemáticamente, la diferencia entre medias se expresa como:

$$\bar{x}_1 - \bar{x}_2$$

donde:

- $\bar{x}_1$ representa la media del primer grupo.
- $\bar{x}_2$ representa la media del segundo grupo.

Sin embargo, la diferencia de medias por sí sola no permite determinar si la diferencia observada es estadísticamente significativa. Para esto, se emplea la prueba t de Student.

La prueba t evalúa la hipótesis nula:

$$H_0 : \mu_1 = \mu_2$$

contra la hipótesis alternativa:

$$H_1 : \mu_1 \neq \mu_2$$

donde:

- μ_1 y μ_2 representan las medias poblacionales de ambos grupos.

El estadístico de prueba se calcula mediante:

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

donde:

- s_1^2 y s_2^2 son las varianzas muestrales.
- n_1 y n_2 representan el tamaño de muestra de cada grupo.

3.5.2. Diagramas de caja (Boxplots)

Los diagramas de caja, también conocidos como boxplots, son herramientas gráficas utilizadas para representar la distribución de una variable numérica, permiten visualizar medidas estadísticas importantes como la mediana, los cuartiles y los valores atípicos.

Un boxplot se compone de una caja central que representa el rango intercuartílico, definido como la diferencia entre el tercer y el primer cuartil:

$$IQR = Q_3 - Q_1$$

donde:

- Q_1 representa el primer cuartil.
- Q_3 representa el tercer cuartil.

3.5.3. K-Nearest Neighbors (KNN)

K-Nearest Neighbors (KNN) es un algoritmo de aprendizaje supervisado utilizado para tareas de clasificación. Su funcionamiento consiste en clasificar un nuevo dato de acuerdo con la categoría predominante entre sus vecinos más cercanos dentro del conjunto de entrenamiento.

La distancia entre observaciones se calcula comúnmente mediante la distancia euclidiana:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

donde:

- x_i y y_i representan las características de dos observaciones.
- n corresponde al número de variables utilizadas.

El parámetro k representa el número de vecinos más cercanos considerados para realizar la clasificación. El algoritmo asigna la clase más frecuente entre dichos vecinos.

3.5.4. Regresión logística

La regresión logística es un método estadístico de clasificación utilizado para modelar la probabilidad de pertenencia a una determinada categoría a partir de un conjunto de variables independientes. A diferencia de la regresión lineal, este modelo se emplea cuando la variable objetivo es categórica.

La regresión logística utiliza la función sigmoide para transformar los valores obtenidos en probabilidades comprendidas entre 0 y 1:

$$P(Y = 1) = \frac{1}{1 + e^{-z}}$$

donde:

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

En estas expresiones:

- $P(Y = 1)$ representa la probabilidad de pertenecer a una clase.
- β_0 corresponde al intercepto del modelo.
- $\beta_1, \beta_2, \dots, \beta_n$ representan los coeficientes asociados a cada variable.
- $x_1, x_2, \dots, x_n$ corresponden a las variables predictoras.

4. Resultados

En esta sección se presentan los resultados obtenidos a partir del análisis estadístico y los modelos de clasificación aplicados a la base de datos de jugadoras de la NWSL 2024. Se analizaron diferencias entre posiciones, distribuciones de variables estadísticas y el desempeño de distintos algoritmos de aprendizaje supervisado.

4.1. Análisis descriptivo

FORWARD = Delantera

Prueba t

Con el objetivo de identificar diferencias estadísticas entre delanteras y otras posiciones dentro del campo, se aplicó una prueba t de muestras independientes sobre las variables de rendimiento de las jugadoras.

La Tabla 1 muestra las variables que presentaron diferencias estadísticamente significativas ($p < 0,05$), indicando que existen variaciones relevantes entre los grupos analizados.

Variable	p-value
total_offside	$6,03 \times 10^{-23}$
on_target_scoring_attempts	$2,68 \times 10^{-19}$
total_scoring_attempts	$4,06 \times 10^{-19}$
goals_avg_over_90_mins	$3,79 \times 10^{-18}$
goals	$1,15 \times 10^{-16}$
goals_and_assists	$1,69 \times 10^{-12}$
long_balls	$3,16 \times 10^{-9}$
successful_dribble	$4,02 \times 10^{-9}$
accurate_passes	$2,67 \times 10^{-8}$
accurate_shooting_percentage	$2,98 \times 10^{-8}$
successful_short_passes	$6,97 \times 10^{-8}$
total_passes	$1,68 \times 10^{-7}$
accurate_pass_percentage	$2,98 \times 10^{-6}$
interceptions	$6,19 \times 10^{-4}$
total_attacking_assists	$1,47 \times 10^{-3}$
assists	$1,47 \times 10^{-3}$
headed_duel	$1,23 \times 10^{-2}$
fouls_suffered	$2,44 \times 10^{-2}$

Tabla 1. Variables con diferencias estadísticamente significativas obtenidas mediante la prueba t.

La prueba t de muestras independientes permitió identificar variables con diferencias estadísticamente significativas entre delanteras y otras posiciones. Destacan principalmente variables ofensivas como goles, tiros totales y tiros a portería, las cuales presentan valores p extremadamente bajos, indicando una fuerte evidencia de diferencia. Asimismo, variables relacionadas con la distribución del balón, como pases, también resultaron significativas, aunque en sentido negativo, lo que refleja una menor participación de las delanteras en la construcción del juego. Finalmente, variables como el fuera de lugar y las faltas recibidas se interpretan como consecuencias del rol ofensivo.

Diferencia de medias

La diferencia de medias permite cuantificar la magnitud de las diferencias entre delanteras y otras posiciones, complementando el análisis de significancia estadística obtenido mediante la prueba t.

La Figura 1 muestra la diferencia de medias entre delanteras y otras posiciones para distintas variables estadísticas de rendimiento.




Figura 1: Diferencia de medias entre delanteras y otras posiciones

Las variables con mayores diferencias de medias entre delanteras y otras posiciones se presentan en la Tabla 2. Estas diferencias permiten identificar qué métricas muestran un mayor contraste en el rendimiento de las jugadoras según su posición dentro del campo.

Variable	Diferencia de medias
goals	1.208333
dribble_percentage	1.347021
fouls_suffered	1.566023
goals_and_assists	1.579911
total_offside	1.799919
successful_dribble	3.197464
on_target_scoring_attempts	3.619163
headed_duel	3.716586
total_scoring_attempts	6.159622
tackles_percentage	6.403180
turnovers	6.981683
accurate_shooting_percentage	22.553543

Tabla 2. Variables con mayores diferencias de medias entre delanteras y otras posiciones.

Las siguientes variables corresponden a aquellas que presentaron las mayores diferencias de medias entre delanteras y otras posiciones. Debido a su relevancia estadística y relación con el rendimiento ofensivo de las jugadoras, estas métricas serán analizadas con mayor detalle en las siguientes secciones.

- **accurate_shooting_percentage** (+22.55)

- **total_scoring_attempts** (+6.15)
- **on_target_scoring_attempts** (+3.61)
- **successful_dribble** (+3.19)
- **goals_and_assists** (+1.57)
- **goals** (+1.20)

El análisis de diferencia de medias y pruebas estadísticas muestra que las delanteras se caracterizan principalmente por variables ofensivas como tiros totales, tiros a portería, goles y porcentaje de efectividad en el disparo, las cuales presentan las mayores diferencias respecto a otras posiciones. Asimismo, destacan en acciones individuales como el regate y en su contribución directa a la generación de goles.

En contraste, variables relacionadas con la distribución del balón, como pases totales y pases precisos, presentan valores significativamente menores, lo que indica una baja participación en la construcción del juego. Esto refuerza el rol de la delantera como finalizadora de las jugadas más que como generadora de posesión. Por otro lado, variables como pérdidas de balón, faltas y fuera de lugar muestran valores elevados; sin embargo, estas no se interpretan como habilidades, sino como consecuencias del estilo de juego ofensivo, caracterizado por un mayor riesgo en la toma de decisiones.

Diagramas de caja (Boxplots)

Con el objetivo de analizar de manera más detallada la distribución de las variables con mayores diferencias de medias, se realizaron diagramas de caja (boxplots) para cada una de ellas.

Estas gráficas facilitan la comparación del comportamiento estadístico de las variables más relevantes dentro del análisis.

accurate_shooting_percentage (porcentaje de precisión de tiro)

El boxplot presentado en la Figura 2 muestra que las delanteras presentan valores considerablemente más altos en comparación con las demás posiciones, lo que indica una mayor precisión en los disparos realizados durante el juego.

Esto coincide con las funciones ofensivas propias de las delanteras, quienes son las principales responsables de finalizar las jugadas de ataque y generar oportunidades de gol.




Figura 2: Boxplot de la variable `accurate_shooting_percentage` según la posición de juego

total_scoring_attempts (intentos totales de gol)

El boxplot presentado en la Figura 3 muestra que las delanteras presentan una mayor cantidad de intentos totales de gol en comparación con las demás posiciones.

La distribución de esta variable evidencia una participación ofensiva más activa por parte de las delanteras, quienes constantemente buscan generar oportunidades de anotación y finalizar las jugadas de ataque.




Figura 3: Boxplot de la variable total_scoring_attempts según la posición de juego

successful_dribble (regate)

El boxplot presentado en la Figura 4 muestra que las delanteras presentan mayores valores en comparación con las demás posiciones.

Esto indica una mayor capacidad para superar rivales mediante el regate, habilidad que resulta fundamental en acciones ofensivas y en la generación de oportunidades de ataque dentro del juego.




Figura 4: Boxplot de la variable successful_dribble según la posición de juego

MIDFIELDER = Centrocampista

Prueba t

Con el objetivo de analizar las características estadísticas asociadas a las centrocampistas, se aplicó nuevamente una prueba t de muestras independientes comparando esta posición con el resto de las jugadoras.

La Tabla 3 muestra las variables que presentaron diferencias estadísticamente significativas ($p < 0,05$), permitiendo identificar las métricas con mayor relevancia para esta posición dentro del campo.

Variable	p-value
tackles	0.000340
tackles.1	0.000340
fouls_committed	0.002877
total_offside	0.003579
yellow_cards	0.004997
long_balls	0.005338
fouls_suffered	0.018544
goals_avg_over_90_mins	0.021732
goals	0.037698

Tabla 3. Variables con diferencias estadísticamente significativas para centrocampistas obtenidas mediante la prueba t.

El análisis muestra que las centrocampistas se caracterizan principalmente por su participación en tareas defensivas y de recuperación de balón, destacando variables como tackles. Asimismo, presentan una alta interacción física en el juego, reflejada en faltas cometidas, faltas recibidas y tarjetas amarillas. Además, contribuyen a la distribución del balón mediante acciones como pases largos. Aunque también presentan diferencias en variables ofensivas como goles, estas no constituyen su principal característica, lo que confirma su rol como enlace entre defensa y ataque.

Diferencia de medias

La Figura 5 muestra las variables con mayores diferencias de medias en las centrocampistas. Estas métricas permiten visualizar de manera comparativa el comportamiento estadístico entre esta posición y el resto de las jugadoras.




Figura 5: Variables con mayores diferencias de medias en centrocampistas

Las variables con mayores diferencias de medias entre centrocampistas y otras posiciones se presentan en la Tabla 4. Estas diferencias permiten identificar las métricas que muestran un mayor contraste en el rendimiento de las jugadoras, así como las características más representativas del rol de las centrocampistas dentro del campo.

Variable	Diferencia de medias
tackles	2.512148
tackles.1	2.512148
dribble_percentage	3.645371
tackles_percentage	5.383377
fouls_committed	1.763533
fouls_suffered	1.589486
interceptions	0.714468
accurate_pass_percentage	1.134075
accurate_shooting_percentage	1.191949
yellow_cards	0.331944

Tabla 4. Variables con mayores diferencias de medias en centrocampistas.

Las siguientes variables corresponden a aquellas que presentaron las mayores diferencias de medias entre centrocampistas y otras posiciones. Debido a su relevancia estadística y a su relación con el desempeño táctico y de recuperación de balón, estas métricas serán analizadas con mayor detalle en las siguientes secciones.

- **tackles** (+2.51)
- **tackles_percentage** (+5.38)

- **interceptions** (+0.71)
- **fouls_committed** (+1.76)
- **fouls_suffered** (+1.58)
- **dribble_percentage** (+3.64)
- **accurate_pass_percentage** (+1.13)

El análisis de diferencia de medias muestra que las centrocampistas se caracterizan principalmente por una mayor participación en tareas defensivas, destacando variables como tackles, porcentaje de tackles e intercepciones, las cuales presentan los valores más altos respecto a otras posiciones. Asimismo, presentan una alta interacción física en el juego, reflejada en el número de faltas cometidas y recibidas.

Por otro lado, también destacan en aspectos técnicos como el control y la eficiencia, evidenciado en el porcentaje de regate y la precisión en los pases, lo que sugiere un estilo de juego más controlado.

En contraste, variables ofensivas como goles, tiros totales y tiros a portería presentan valores negativos, lo que indica que las centrocampistas no se enfocan en la finalización de jugadas. Esto refuerza su rol como jugadoras de equilibrio dentro del equipo, participando tanto en la recuperación del balón como en la organización del juego.

Diagramas de caja (Boxplots)

Con el objetivo de analizar la distribución y variabilidad de las principales variables asociadas a las centrocampistas, se presentan a continuación los diagramas de caja (boxplots). Estas gráficas permiten observar la dispersión de los datos, la mediana y la presencia de valores atípicos, facilitando la comparación entre posiciones de juego.

tackles (entradas defensivas)

La Figura 6 muestra el boxplot de la variable tackles, donde se observa que las centrocampistas presentan valores un poco superiores en comparación con las demás posiciones, lo que refleja su participación activa en la recuperación del balón.




Figura 6: Boxplot de la variable successful_dribble según la posición de juego

interceptions (intercepciones)

La figura 7 muestra el boxplot de la variable interceptions, las defensas presentan valores superiores en comparación con las centrocampistas y el resto de posiciones. Esto es coherente con su rol dentro del campo,

ya que una de sus principales funciones es la recuperación del balón y la interrupción de las jugadas ofensivas del equipo rival.

En contraste, las centrocampistas presentan valores intermedios, lo que refleja su participación tanto en tareas defensivas como en la distribución del juego.




Figura 7: Boxplot de la variable interceptions según la posición de juego

fouls_committed (faltas cometidas)

La figura 8 muestra el boxplot de la variable fouls_committed muestra una distribución muy similar entre delanteras, defensas y centrocampistas, con medianas y rangos intercuartílicos prácticamente equivalentes entre las tres posiciones.

Esto sugiere que no existen diferencias marcadas en la cantidad de faltas cometidas según la posición, lo que indica que esta variable no discrimina de forma clara entre roles dentro del campo y puede estar más relacionada con el estilo de juego o la intensidad del partido que con la posición específica de la jugadora.




Figura 8: Boxplot de la variable fouls_committed según la posición de juego

Aunque los boxplot no muestra una separación visual marcada entre grupos, la prueba t confirma que las diferencias son estadísticamente significativas, lo que indica que estas pueden no ser evidentes a simple vista debido a la variabilidad de los datos.

DEFENDER = Defensa

Prueba t

Las siguientes variables mostradas en la Tabla 5 corresponden a aquellas que presentaron diferencias estadísticamente significativas ($p < 0,05$) entre defensas y otras posiciones. Debido a su relevancia estadística y a su relación con el rendimiento defensivo, estas métricas serán analizadas con mayor detalle en las siguientes secciones.

Variable	p-value
successful_short_passes	$9,06 \times 10^{-11}$
accurate_passes	$2,20 \times 10^{-10}$
total_passes	$2,81 \times 10^{-9}$
total_scoring_attempts	$5,05 \times 10^{-9}$
on_target_scoring_attempts	$1,34 \times 10^{-8}$
total_offside	$1,07 \times 10^{-6}$
goals_avg_over_90_mins	$3,38 \times 10^{-6}$
interceptions	$3,65 \times 10^{-6}$
goals	$1,09 \times 10^{-5}$
goals_and_assists	$2,08 \times 10^{-5}$
long_balls	$1,08 \times 10^{-3}$
successful_dribble	$1,48 \times 10^{-3}$
accurate_shooting_percentage	$1,51 \times 10^{-3}$
accurate_pass_percentage	$4,13 \times 10^{-3}$
fouls_suffered	$7,98 \times 10^{-3}$
total_attacking_assists	$8,07 \times 10^{-3}$
assists	$8,07 \times 10^{-3}$

Tabla 5. Variables con diferencias estadísticamente significativas para defensas obtenidas mediante la prueba t.

Las defensas se caracterizan por una alta participación en la distribución del balón, destacando en pases totales y pases precisos, así como en acciones defensivas como intercepciones. En contraste, presentan valores significativamente menores en variables ofensivas como goles y tiros, lo que confirma su rol centrado en la contención y el inicio del juego desde zonas defensivas.

Diferencia de medias

La Figura 9 muestra las variables con mayores diferencias de medias en las defensas. Estas métricas permiten visualizar de manera comparativa el comportamiento estadístico entre esta posición y el resto de las jugadoras, destacando las características más representativas del rendimiento defensivo dentro del campo.




Figura 9: Variables con mayores diferencias de medias en defensas

Las variables con mayores diferencias de medias entre defensas y otras posiciones se presentan en la Tabla 6. Estas diferencias permiten identificar las métricas que muestran un mayor contraste en el rendimiento de las jugadoras, así como las características más representativas del rol de las defensas dentro del campo.

Variable	Diferencia de medias
accurate_passes	111.854066
total_passes	126.835346
successful_short_passes	106.054952
minutes_played	71.637882
long_balls	5.915862
tackles_percentage	5.721216
accurate_pass_percentage	4.155395
interceptions	3.481481
dribble_percentage	2.586957
headed_duel	0.833736
tackles	0.603462

Tabla 6. Variables con mayores diferencias de medias en defensas.

Las siguientes variables corresponden a aquellas que presentaron las mayores diferencias de medias entre defensas y otras posiciones. Estas métricas permiten identificar los aspectos más característicos del desempeño defensivo, así como los contrastes más relevantes en la participación táctica y en la distribución del juego dentro del campo. Su análisis detallado se presenta en las siguientes secciones.

- **total_passes** (+126.83)
- **accurate_passes** (+111.85)

- **successful_short_passes** (+106.05)
- **minutes_played** (+71.63)
- **tackles_percentage** (+5.72)
- **long_balls** (+5.91)
- **accurate_pass_percentage** (+4.15)
- **interceptions** (+3.48)

El análisis de diferencia de medias muestra que las defensas se caracterizan principalmente por una alta participación en la distribución del balón, destacando variables como pases totales, pases precisos y pases cortos exitosos, las cuales presentan las mayores diferencias respecto a otras posiciones. Esto sugiere que las defensas cumplen un rol importante en la salida de balón y en la construcción inicial del juego desde zonas bajas.

Asimismo, destacan en acciones defensivas como intercepciones y porcentaje de tackles, lo que confirma su función principal de recuperación y contención del rival. También presentan valores relevantes en balones largos, lo que indica su participación en cambios de juego o despejes estratégicos.

En contraste, variables ofensivas como goles, tiros a portería y efectividad de disparo presentan valores negativos, lo que refuerza su bajo involucramiento en la finalización de jugadas.

En conjunto, estos resultados confirman que las defensas no solo cumplen una función de contención, sino que también son clave en la organización y salida del juego desde la línea defensiva.

Diagramas de caja (Boxplots)

A continuación, se presentan los diagramas de caja correspondientes a las variables con mayores diferencias de medias en las defensas. Estas visualizaciones permiten analizar la distribución de los datos y comparar el comportamiento estadístico de esta posición frente al resto de las jugadoras.

total_passes (total de pases)

La figura 10 muestra el boxplot de la variable total_passes muestra que las defensas presentan valores significativamente superiores en comparación con las demás posiciones. Esto indica una mayor participación en la distribución del balón y en la construcción del juego desde zonas defensivas.

Este comportamiento es coherente con el rol de las defensas, quienes suelen iniciar las acciones ofensivas mediante pases cortos y largos, contribuyendo a la salida de balón del equipo.




Figura 10: Boxplot de la variable total_passes según la posición de juego

accurate_passes (pases precisos)

La figura 11 muestra el boxplot de la variable `accurate_passes` muestra que las defensas presentan valores notablemente más altos en comparación con las demás posiciones. Esto indica una mayor precisión en la distribución del balón, lo cual es fundamental para la construcción del juego desde la zona defensiva. Este comportamiento es consistente con el rol de las defensas, quienes no solo buscan recuperar el balón, sino también asegurar una salida limpia y efectiva mediante pases precisos hacia las zonas medias y ofensivas.




Figura 11: Boxplot de la variable `accurate_passes` según la posición de juego

interceptions (intercepciones)

La figura 12 muestra el boxplot de la variable `interceptions` muestra que las defensas presentan valores superiores en comparación con las demás posiciones, incluyendo las centrocampistas. Esto evidencia su papel principal en la recuperación del balón y en la interrupción de las jugadas ofensivas del equipo rival. Este resultado es coherente con las funciones tácticas de las defensas, quienes tienen como objetivo principal anticipar las acciones del adversario y recuperar la posesión en zonas defensivas.




Figura 12: Boxplot de la variable `interceptions` según la posición de juego

GOALKEEPER = Portera

Prueba t

A continuación, se realiza el análisis de las porteras mediante la prueba t de muestras independientes, con el objetivo de comparar su desempeño estadístico frente al resto de las posiciones.

Dado que la función de la portera es altamente específica dentro del juego, se espera que existan diferencias significativas en variables relacionadas con acciones defensivas directas, así como en aquellas vinculadas a la participación general dentro del partido.

La Tabla 7 presenta las variables que resultaron estadísticamente significativas en las porteras ($p < 0,05$), permitiendo identificar las métricas con mayor diferencia respecto a las demás posiciones.

Variable	p-value
long_balls	$1,33 \times 10^{-26}$
tackles_percentage	$3,14 \times 10^{-21}$
tackles	$1,57 \times 10^{-7}$
tackles.1	$1,57 \times 10^{-7}$
fouls_committed	$3,11 \times 10^{-7}$
accurate_shooting_percentage	$2,13 \times 10^{-6}$
interceptions	$7,57 \times 10^{-5}$
headed_duel	$1,06 \times 10^{-4}$
successful_dribble	$1,42 \times 10^{-4}$
dribble_percentage	$2,01 \times 10^{-4}$
fouls_suffered	$2,10 \times 10^{-4}$
total_scoring_attempts	$2,23 \times 10^{-4}$
on_target_scoring_attempts	$1,68 \times 10^{-3}$
yellow_cards	$4,37 \times 10^{-3}$
goals_and_assists	$5,51 \times 10^{-3}$
goals	$1,19 \times 10^{-2}$
total_offside	$1,30 \times 10^{-2}$
goals_avg_over_90_mins	$2,22 \times 10^{-2}$
minutes_played	$2,55 \times 10^{-2}$
assists	$2,85 \times 10^{-2}$
total_attacking_assists	$2,85 \times 10^{-2}$

Tabla 7. Variables con diferencias estadísticamente significativas para porteras obtenidas mediante la prueba t.

El análisis de la prueba t muestra que las porteras se diferencian principalmente por su participación en acciones de salida de balón, destacando la variable de balones largos como la más significativa. Asimismo, presentan valores significativamente distintos en casi todas las variables de campo, lo que se explica por su rol altamente especializado.

En contraste, variables ofensivas como goles, asistencias y tiros presentan diferencias importantes, lo cual no refleja participación activa, sino su ausencia en este tipo de acciones. En conjunto, estos resultados confirman el rol exclusivo de las porteras como última línea defensiva y su limitada participación en acciones ofensivas o de campo.

Diferencia de medias

La Figura 13 muestra las variables con mayores diferencias de medias en las porteras. Estas métricas permiten visualizar de manera comparativa el comportamiento estadístico de esta posición frente al resto de las jugadoras, destacando los aspectos más representativos de su rendimiento dentro del campo.




Figura 13: Variables con mayores diferencias de medias en porteras

Las variables con mayores diferencias de medias entre porteras y otras posiciones se presentan en la Tabla 8. Estas diferencias permiten identificar las métricas que muestran un mayor contraste en el rendimiento de las jugadoras, así como las características más representativas del rol de las porteras dentro del campo.

Variable	Diferencia de medias
minutes_played	163.592334
total_passes	40.912892
accurate_passes	30.139373
long_balls	32.341463
accurate_pass_percentage	4.397213
tackles_percentage	0.000000
interceptions	-5.428571
tackles	-6.801394
dribble_percentage	-25.742160
accurate_shooting_percentage	-35.261324

Tabla 8. Variables con mayores diferencias de medias para porteras.

Las variables con mayor relevancia para su interpretación corresponden a aquellas que presentan las diferencias de medias más altas en valor absoluto y positivo. En este sentido, se recomienda enfocar la atención en las siguientes métricas, ya que reflejan de manera más clara el perfil característico de las porteras dentro del conjunto de datos:

- **minutes_played (+163.59)**
- **total_passes (+40.91)**

- **accurate_passes (+30.13)**
- **long_balls (+32.34)**
- **accurate_pass_percentage (+4.39)**

El análisis de diferencia de medias muestra que las porteras se caracterizan principalmente por una alta participación en variables relacionadas con la distribución del balón, destacando los pases totales, pases precisos y balones largos como las diferencias más importantes respecto a las demás posiciones. Esto refleja su papel fundamental en la reanudación del juego desde el área y en la salida de balón como primera fase de construcción.

Asimismo, destaca la variable de minutos jugados, lo cual sugiere una participación constante en el campo dentro de su rol específico, ya que las porteras suelen tener menor rotación en comparación con los jugadores de campo.

En contraste, la mayoría de las variables ofensivas y defensivas de campo presentan valores negativos, lo que no indica un bajo rendimiento, sino su ausencia natural en este tipo de acciones debido a su posición altamente especializada.

En conjunto, estos resultados confirman que las porteras cumplen un rol completamente diferenciado dentro del equipo, centrado en la organización defensiva, la distribución del balón y la iniciación del juego desde el área.

Diagramas de caja (Boxplots)

long_balls (Balones largos)

La Figura 14 muestra el diagrama de caja correspondiente a la variable long_balls. En este se observa que las porteras presentan valores significativamente superiores en comparación con el resto de las posiciones, lo cual evidencia su papel fundamental en la distribución del balón mediante pases largos desde zonas defensivas.

Este comportamiento es consistente con su función dentro del juego, ya que suelen ser responsables de iniciar las transiciones ofensivas a través de envíos largos y despejes dirigidos hacia zonas más avanzadas del campo.




Figura 14: Diagrama de caja de la variable long_balls

minutes_played (Minutos jugados)

La Figura 15 muestra el diagrama de caja correspondiente a la variable minutes_played. En este se observa que las porteras presentan valores más altos en comparación con el resto de las posiciones, lo que indica que suelen acumular una mayor cantidad de minutos jugados.

Este resultado es consistente con la naturaleza de su rol, ya que las porteras suelen ser titulares habituales y presentan menor rotación en comparación con jugadores de campo, lo que se refleja en una mayor continuidad dentro de los partidos.




Figura 15: Diagrama de caja de la variable minutes_played por posición.

En conjunto, el análisis descriptivo permitió identificar diferencias claras entre las distintas posiciones dentro del fútbol femenino profesional. Las variables relacionadas con la ofensiva, como tiros, goles y efectividad de disparo, resultaron más representativas en las delanteras, mientras que las centrocampistas destacaron en acciones de recuperación y equilibrio del juego. Por otro lado, las defensas mostraron una mayor participación en la distribución del balón y acciones defensivas, y las porteras presentaron un perfil altamente especializado centrado en la salida de juego y la acumulación de minutos.

Estos resultados evidencian que las variables seleccionadas capturan adecuadamente las características propias de cada posición, lo que proporciona una base sólida para la siguiente etapa del análisis, en la cual se aplicarán modelos de clasificación para predecir la posición de las jugadoras a partir de sus estadísticas.

4.2. Modelos de clasificación

4.2.1. K-Nearest Neighbors (KNN)

En esta sección se presentan los resultados obtenidos mediante la aplicación del algoritmo K-Nearest Neighbors (KNN) para la clasificación de las jugadoras según su posición en el campo.

El modelo KNN fue evaluado utilizando K-Fold Cross-Validation (con $k = 5$) para obtener una estimación más robusta de su rendimiento. A continuación, se resumen los resultados clave:

Precisión (Accuracy)

La precisión (*accuracy*) promedio del modelo KNN fue de 0,5810, con una desviación estándar de $\pm 0,0417$. Esto indica que el modelo clasifica correctamente la posición de las jugadoras aproximadamente el 58,10 % de las veces, con una variabilidad moderada entre los diferentes folds de la validación cruzada.

Clasificación Promedio

- **DEFENDER (Defensa):** El modelo mostró una precisión de 0,53 y un recall de 0,64. Esto significa que cuando predice que una jugadora es defensa, acierta el 53 % de las veces, y es capaz de identificar correctamente al 64 % de las defensas reales.
- **FORWARD (Delantera):** Para las delanteras, la precisión fue de 0,70 y el recall de 0,63. Es la clase con mayor precisión promedio, indicando que el modelo es relativamente bueno cuando clasifica a una

jugadora como delantera.

- **GOALKEEPER (Portera):** Las porteras obtuvieron una alta precisión de 0,80 y un recall de 0,62. A pesar de ser una clase minoritaria, el modelo tiende a ser preciso cuando identifica a una portera.
- **MIDFIELDER (Centrocampista):** Las centrocampistas tuvieron la precisión más baja con 0,48 y un recall de 0,45, lo que sugiere que el modelo tiene más dificultades para distinguir correctamente a las centrocampistas de otras posiciones.

Matriz de Confusión Promedio

La matriz de confusión promedio (mostrada en la Figura 16) visualiza la cantidad de aciertos y errores para cada clase. Se observa que:

- Existe una tendencia a confundir a las **MIDFIELDER** con otras posiciones, especialmente con **DEFENDER** y **FORWARD**, lo que se alinea con el bajo recall y precisión para esta clase.
- Las **GOALKEEPER** son relativamente bien clasificadas, aunque con un menor número de muestras.
- **FORWARD** muestra un buen balance entre predicciones correctas y capacidad de identificar a las jugadoras de esa posición.

En conclusión, el modelo KNN proporciona una base para la clasificación de posiciones, destacando en la identificación de **FORWARD** y **GOALKEEPER**. Sin embargo, presenta limitaciones con **MIDFIELDER**, lo que sugiere que podría ser necesario explorar otros modelos o técnicas de mejora para esta clase.




Figura 16: Matriz de confusión promedio del modelo KNN para la clasificación de posiciones.

4.2.2. Modelo de Regresión Logística

El modelo de Regresión Logística fue evaluado utilizando K-Fold Cross-Validation (con $k = 5$) para obtener una estimación más robusta de su rendimiento. A continuación, se resumen los resultados clave:

Precisión (Accuracy)

La precisión (*accuracy*) promedio del modelo de Regresión Logística fue de 0,6882, con una desviación estándar de $\pm 0,0355$. Esto indica que el modelo clasifica correctamente la posición de las jugadoras aproximadamente el 68,82 % de las veces, lo que representa una mejora significativa con respecto al modelo KNN.

Clasificación Promedio

- **DEFENDER (Defensa):** El modelo mostró una precisión de 0,66 y un recall de 0,66. Esto significa que cuando predice que una jugadora es defensa, acierta el 66 % de las veces, y es capaz de identificar correctamente al 66 % de las defensas reales.
- **FORWARD (Delantera):** Para las delanteras, la precisión fue de 0,82 y el recall de 0,72. Es la clase con mayor precisión promedio, indicando un rendimiento muy sólido en la identificación de delanteras.
- **GOALKEEPER (Portera):** Las porteras obtuvieron una precisión de 0,87 y un recall de 0,90. A pesar de ser una clase minoritaria, el modelo es altamente preciso y tiene un excelente recall para identificar a las porteras.
- **MIDFIELDER (Centrocampista):** Las centrocampistas tuvieron una precisión de 0,59 y un recall de 0,65, mostrando una mejora en comparación con el modelo KNN, aunque sigue siendo la clase con menor rendimiento.

Matriz de Confusión Promedio

Como se muestra en la **Figura 17**, la matriz de confusión promedio visualiza la cantidad de aciertos y errores para cada clase. Se observa que:

- El modelo presenta un buen rendimiento general, con menos errores de clasificación en comparación con el modelo KNN.
- Las **GOALKEEPER** son clasificadas con alta precisión.
- Persiste cierta confusión con las **MIDFIELDER**, aunque en menor medida que en el modelo KNN, observándose todavía algunas clasificaciones erróneas con **DEFENDER** y **FORWARD**.




Figura 17: Matriz de confusión promedio del modelo Regresión Logística para la clasificación de posiciones.

En conclusión, el modelo de Regresión Logística muestra un rendimiento superior al KNN, con una mayor precisión global y una mejor capacidad para distinguir entre las diferentes posiciones, especialmente **FORWARD** y **GOALKEEPER**. Aunque la clasificación de **MIDFIELDER** aún presenta desafíos, la Regresión Logística ofrece una base más robusta para la predicción de posiciones.

4.3. Tabla comparativa KNN vs Regresión Logística

Con el objetivo de comparar el desempeño de los modelos utilizados, se presenta en la Tabla 9 una evaluación entre KNN y Regresión Logística en términos de exactitud global y desempeño por clase. Esta comparación permite identificar el modelo con mejor capacidad predictiva para la clasificación de posiciones en el fútbol femenino profesional.

Métrica	KNN	Regresión Logística
Accuracy	0.5810 ± 0.0417	0.6882 ± 0.0355
DEFENDER (F1-score aprox.)	0.58	0.66
FORWARD (F1-score aprox.)	0.66	0.77
GOALKEEPER (F1-score aprox.)	0.69	0.88
MIDFIELDER (F1-score aprox.)	0.46	0.62

Tabla 9. Comparación del desempeño entre KNN y Regresión Logística en la clasificación de posiciones.

A partir de la Tabla 9, se observa que el modelo de Regresión Logística supera al modelo KNN en todas las métricas evaluadas, tanto en la exactitud global como en el desempeño por clase.

En particular, se aprecia una mejora significativa en la clasificación de las **GOALKEEPER** y **MIDFIELDER**, lo que indica una mayor capacidad del modelo para capturar las diferencias entre posiciones con características más complejas o menos evidentes.

Asimismo, el incremento en el rendimiento de las clases **FORWARD** y **DEFENDER** confirma que la Regresión Logística ofrece una mejor separación entre las categorías del problema. En conjunto, estos resultados sugieren que este modelo presenta una mayor robustez y capacidad predictiva para la tarea de clasificación de posiciones en comparación con KNN.

5. Conclusión general

En este trabajo se abordó el problema de la clasificación de posiciones en el fútbol femenino profesional utilizando datos estadísticos de rendimiento de jugadoras de la National Women's Soccer League (NWSL). El objetivo principal consistió en analizar si, a partir de variables cuantitativas del desempeño en el campo, era posible diferenciar de manera consistente entre las posiciones de delanteras, centrocampistas, defensas y porteras mediante técnicas de aprendizaje supervisado.

En una primera parte, el análisis descriptivo permitió identificar patrones generales asociados a cada posición. Las delanteras se caracterizaron por una mayor participación en acciones ofensivas, destacando variables como goles, intentos de disparo y efectividad en la finalización, lo cual es consistente con su función principal dentro del juego. Las centrocampistas mostraron un perfil más equilibrado, con participación tanto en acciones defensivas como en la generación de juego, lo que refleja su papel de enlace entre defensa y ataque. Por su parte, las defensas presentaron valores elevados en variables relacionadas con la recuperación de balón, intercepciones y distribución del juego desde zonas bajas. Finalmente, las porteras mostraron un comportamiento altamente diferenciado, con una fuerte presencia en variables de distribución como pases largos y total de pases, además de una menor participación en acciones típicas de campo.

Posteriormente, se aplicaron modelos de aprendizaje supervisado con el fin de evaluar la capacidad predictiva de las variables seleccionadas. En particular, se implementaron los algoritmos K-Nearest Neighbors y Regresión Logística, utilizando validación cruzada para obtener estimaciones más robustas del desempeño. Los resultados obtenidos muestran que la Regresión Logística presenta un rendimiento superior al modelo KNN, tanto en términos de precisión global como en la estabilidad de las predicciones entre los distintos subconjuntos de validación.

En el análisis por clase, se observó que las posiciones de portera y delantera fueron las más fáciles de clasificar, debido a que presentan características más diferenciadas respecto al resto de posiciones. En el caso de las porteras, su perfil altamente especializado facilita su identificación, mientras que las delanteras se distinguen claramente por sus métricas ofensivas. En contraste, las centrocampistas representaron la clase más difícil de clasificar, ya que sus características tienden a solaparse tanto con defensas como con delanteras, generando

una mayor confusión entre clases. Las defensas, por su parte, presentaron un rendimiento intermedio, con una capacidad de identificación relativamente estable, aunque también con cierto grado de confusión con otras posiciones.

Finalmente, se concluye que el enfoque propuesto permite realizar una clasificación razonablemente efectiva de las posiciones en el fútbol femenino a partir de datos estadísticos de rendimiento. Entre los modelos evaluados, la Regresión Logística se posiciona como la alternativa más adecuada debido a su mejor desempeño global y mayor capacidad de generalización.

Referencias

- [1] Andrade Obando, A. N., Balderramos Mera, K. S., Cuellar Pinto, L. A., & Herrera Bartolomé, J. C. (2024). El fútbol femenino como influencia en el cambio sociocultural en las parroquias urbanas del cantón Sucre. *Revista Científica Multidisciplinaria ULEAM Bahía Magazine*, 5(9). <https://doi.org/10.56124/ubm.v5i9.019>
- [2] Ortégón-Cataño, J. C., Motato, L. A., Galeano, J. D., Asín-Izquierdo, I., Ortiz-García, M., & Usme-Pineda, C. A. (2025). Análisis de la carga técnica de un equipo profesional femenino en Colombia durante competición. *Revista Digital: Actividad Física y Deporte*, 11(1), e2527. <https://doi.org/10.31910/rdafd.v11.n1.2025.2527>
- [3] Ballesta Castells, C., García Romero, J., Fernández García, J. C., & Alvero Cruz, J. R. (2015). Métodos actuales de análisis del partido de fútbol. *Revista Internacional de Medicina y Ciencias de la Actividad Física y del Deporte*, 15(60), 785–803.